



Procesamiento de Señales II

Ciencia de Datos II

Version 2022-2

Análisis y Visualización de Datos - Probabilidad

Capítulo [1]

Dr. José Ramón Iglesias

DSP-ASIC BUILDER GROUP

Director Semillero TRIAC

Ingeniería Electronica

Universidad Popular del Cesar

Primero: ¿cuál es el problema?

Si me dedico a la programación...
¿Cuánto puedo cobrar?...¿ Se podrá
implementar un sistema que, dadas las
características de una persona, devuelva el
sueldo posible?

Encuesta Sysarmy

- Encuesta personal y voluntaria que busca relevar información sobre salarios y condiciones de trabajo de programadores, que se realiza anualmente.
- Usaremos sólo los datos provenientes de un país como Argentina

Demo con Notebook

CIED2_Probabilidad.ipynb

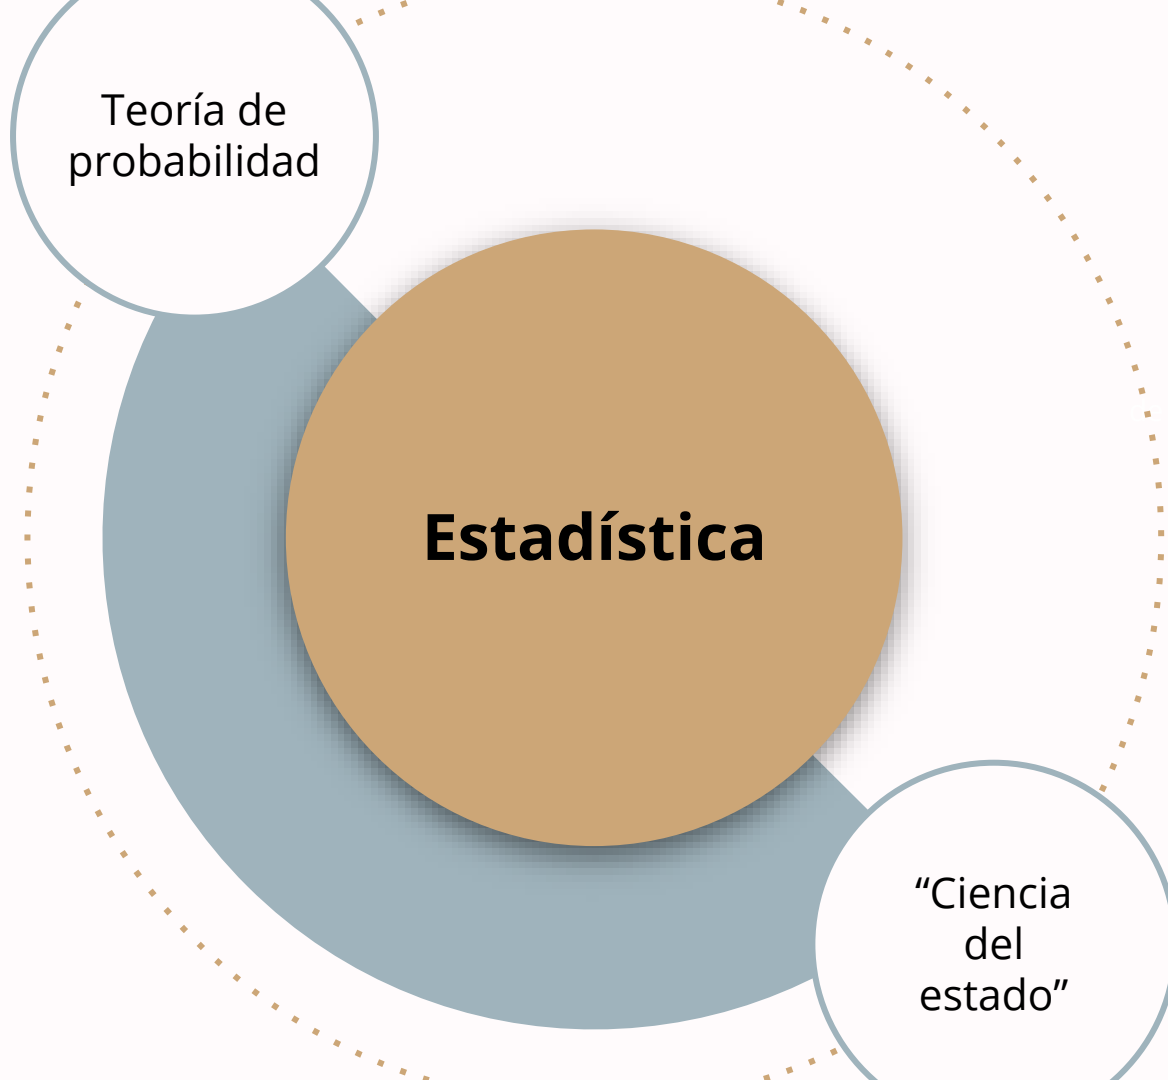
Teoría del azar

Teoría de
probabilidad

Estadística

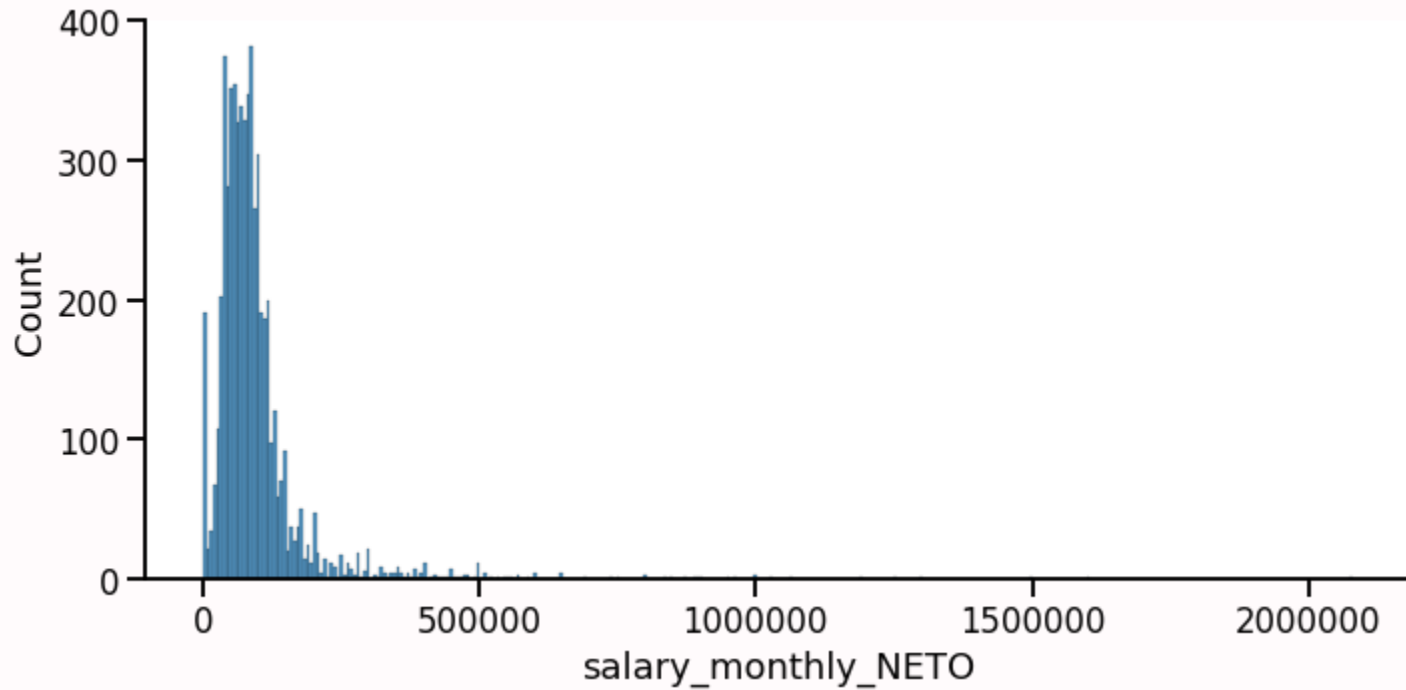
"Ciencia
del
estado"

Recolección y uso
de datos en el
gobierno de un
estado



Utilidad de la Estadística

- **Descripción de datos**
- **Análisis de muestras**
- Medición de relaciones
- Toma de decisiones
- Contrastación de Hipótesis
- Inferencia
- Predicción




¿Cuál es el concepto matemático que usamos para modelar la columna salary_monthly_NETO?

Variable Aleatoria

Una **variable aleatoria (v.a.)** X es una función

$$X: \Omega \rightarrow R_X$$

donde Ω es un conjunto llamado **Espacio de estados** y R_X es un conjunto de valores que toma la variable llamado **Rango**.



Una **variable aleatoria**

(v.a.) X es una función

$$X: \Omega \rightarrow R_X$$

donde Ω es un conjunto

llamado **Espacio de**

estados y R_X es un

conjunto de valores que

toma la variable llamado

Rango.

Podemos utilizar una v.a. X que

represente la columna


salary_monthly_NETO,

En este caso Ω puede ser la población

total de programadores en un país en

2020 (o bien los que hicieron la encuesta)

y R_X el conjunto de salarios posibles.



Una **variable aleatoria**

(v.a.) X es una función

$$X: \Omega \rightarrow R_X$$

donde Ω es un conjunto

llamado **Espacio de**

estados y R_X es un

conjunto de valores que

toma la variable llamado

Rango.

El espacio de estados Ω es el conjunto de estados (personas) que podríamos haber encontrado en nuestra encuesta.

$\Omega = \{\omega / \omega \text{ es una persona viva que trabaja en un país}\}$

Puede tener más de una definición:

$\Omega = \{\omega / \omega \text{ es una persona viva que trabaja en un país como desarrollador/a}\}$

Una **variable aleatoria**

(v.a.) X es una función

$$X: \Omega \rightarrow R_x$$

donde Ω es un conjunto

llamado **Espacio de**

estados y R_x es un

conjunto de valores que

toma la variable llamado

Rango.

El rango R_x es el conjunto de valores posibles de salary_monthly_NETO.

$R_x = \mathbb{R}$? (conjunto de números reales)

$R_x = \mathbb{N}$? (conjunto de números naturales)

¿Cómo podemos calcular el rango de R_x en la encuesta?

Una **variable aleatoria**

(v.a.) X es una función

$$X: \Omega \rightarrow R_X$$

donde Ω es un conjunto

llamado **Espacio de**

estados y R_X es un

conjunto de valores que


toma la variable llamado

Rango.

ω = Persona que respondió primero

$$X(\omega) = 43000.0$$

$X(\omega)$ se denomina **realización** de la v.a. X



Variable Aleatoria - Otros ejemplos

X	Ω (espacio de estados posibles, universo, población que vamos a estudiar,...)	R_X
horas diarias que trabaja	personas que son programadores ...	1 - 24
cantidad de glóbulos rojos en sangre	personas	valores en números enteros positivos.
nivel de estudio	asistentes al curso de Ciencia de Datos 2022-2	{estud., grado, posgrado, estud crónico}
altura al nivel del mar	globo terráqueo	\mathbb{R}

Tipos de variables aleatorias

Las variables aleatorias pueden ser de distinto tipo, de acuerdo a los valores presentes en el Rango y su interpretación.

- Numéricas
 - Continuas
 - Discretas (un conjunto finito o infinito numerable de valores posibles)
- Categóricas
- Ordinales

Determinar los tipos de datos/variable
que estamos usando nos permite
seleccionar las herramientas adecuadas
para obtener información a partir de ellos

Demo con Notebook

[CIED2_Probabilidad.ipynb](#)

Hagamos una pregunta interesante:
¿Tener más años de experiencia
significa que se cobra más?

¿Cómo hacer este análisis?

Plantear una hipótesis

Si no planteamos una hipótesis primero, es difícil determinar qué pasos hay que seguir para poder hacer el análisis

Identificar las variables

Una vez que la hipótesis está definida, hay que determinar QUÉ hay que medir para poder comprobarla.

Diseñar el experimento

Una vez que está definido qué medir, se seleccionan las herramientas para medirlo.

¿Cómo hacer este análisis?

Plantear una hipótesis

Tener más años de
experiencia significa
que se cobra más

Identificar las
variables

salary_monthly_NETO
profile_years_experience

Diseñar el
experimento


????

Teoría de probabilidad

¿Probabilidad? - Interpretación axiomática

P es una **medida de Probabilidad** en el **espacio Ω** si para cada subconjunto **A** de **Ω** , **P(A)** es un número tal que:

- $0 \leq P(A) \leq 1$
- $P(\Omega) = 1$
- $P(A \cup B) = P(A) + P(B)$, para A y B disjuntos (o excluyente)
- $P(\cup_i A_i) = \sum_i P(A_i)$ para A_1, A_2, \dots disjuntos



¿Cómo se calcula?

Si Ω tiene k elementos equiprobables (i.e. si ω_i es un elemento de Ω , $P(\{\omega_i\}) = 1/k$)

Si el conjunto A son los elementos en los que el fenómeno ocurre.

Entonces la probabilidad de un conjunto $A \subset \Omega$ es la proporción de eventos en A .

$$P(\{\omega_i\}) = 1/k \implies |A|/k$$

Situaciones más complejas

Si hay dos situaciones a estudiar, entonces se modela el problema usando las columnas salary_monthly_NETO y profile_years_experience para crear conjuntos de eventos y comprobar si existe una relación entre ellos.

Los conjuntos que se eligen son los que determinan el **experimento**

- $A = \{ \omega_i : \text{salary_monthly_NETO} > \text{avg}(\text{salary_monthly_NETO}) \}$
- $B = \{ \omega_i : \text{profile_years_experience} > 5 \}$

Situaciones más complejas

$A = \{ \omega_i : \text{salary_monthly_NETO} > \text{avg} \}$

$B = \{ \omega_i : \text{profile_years_experience} > 5 \}$

intersección: A & B, A y B

La **probabilidad conjunta** de que ocurran ambos eventos al mismo tiempo se modela usando la intersección de los conjuntos:

$$P(A \cap B)$$

Situaciones más complejas

$A = \{ \omega_i :$
salary_monthly_NETO > avg
 $\}$

$B = \{ \omega_i :$
profile_years_experience > 5
 $\}$

La **probabilidad condicional** de que el salario esté por encima del promedio, suponiendo que ocurre el evento de tener más de 5 años de experiencia, se calcula como:

$$P(B) \neq 0 \implies P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Situaciones más complejas

$A = \{ \omega_i :$
salary_monthly_NETO > avg
 $\}$

$B = \{ \omega_i :$
profile_years_experience > 5
 $\}$

A y B se dicen conjuntos **independientes** si

$$P(A \cap B) = P(A)P(B)$$

$$P(B) \neq 0 \implies P(A|B) = P(A)$$

¿Si uno tiene más de 5 años de experiencia, la probabilidad de cobrar más que el promedio aumenta? ¿Estos eventos, son independientes?

Ejercicio en la Ntb.

¿Son independientes o no?

Teorema de Bayes

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Tiene muchas aplicaciones en la ciencia de datos, incluyendo el aprendizaje bayesiano, pero no profundizamos en este tema porque lo van a ver con mucho más detalle en materias siguientes, cuando vean el clasificador Naive Bayes.